

Hlboké neurónové siete 2023

Zadanie č. 1

Na základe demonštračných ukážok v prednáške pre rozpoznávanie číslíc 0-9 (dataset MNIST) pomocou viacvrstvovej perceptrónovej siete (MLP) a konvolučnej neurónovej siete (CNN), vytvorte a natrénujte MLP sieť a CNN sieť, ktorá bude schopná rozpoznávať vybraných 10 znakov abecedy A, B, C, D, E, F, G, H, I, J. Na trénovanie MLP a CNN sietí použite dataset znakov notMNIST (obr.1).



Obr. 1 Dataset znakov notMNIST

Písmená abecedy sú nasnímané v rastri 28x28, t.j. MLP sieť bude mať 784 vstupov s rozsahom $\langle 0;255 \rangle$, kde hodnota 0 predstavuje čierne a 255 biele políčko. Pre CNN je vstupom obraz o rozmeru 28x28x1. Údaje ku písmenám sa nachádzajú v súbore load **notMNIST_small.mat** v premennej **images**. Príslušnosť do skupiny 0 až 9 (t.j. znaky A až J) vyjadruje premenná **labels**.

```
>> load notMNIST_small           % načítanie dát  
  
>> imshow(images(:,1))          % vykreslenie 1. znaku  
>> labels(1)                     % skupina prislúchajúca k 1. znaku
```

Pri vytváraní a trénovaní MLP a CNN siete použite 60% z celkového počtu dát, zvyšné data použite na testovanie alebo aj na validáciu. Pre natrénovanú NS vyčísľte percentuálnu úspešnosť klasifikácie. (**confusion** , **plotconfusion**). (Zvlášť na trénovacích a testovacích dátach). Nastavte štruktúru siete a parametre trénovania, tak aby ste dosiahli čo najväčšiu percentuálnu úspešnosť klasifikácie na testovacích dátach. Pre naladenú štruktúru siete vykonajte 5 spustení s náhodným rozdelením dát alebo krížovú validáciu. Pre najlepšie natrénovanú CNN zobrazte aj kontingenčnú maticu.

Úlohy:

1. Porovnajte dosiahnuté výsledky (úspešnosti klasifikácie) pre MLP a CNN sieť.
2. Vykonajte porovnanie priebehov tréovania, chyby a úspešnosti troch vybraných štruktúr CNN siete na tréovacích a testovacích dátach pre rozdelenie 60%/40%.
3. Najlepšie natréovanej štruktúry CNN, zobrazte vybrané filtre v 1. a 2. konvolučnej vrstve, zobrazte výslednú mapu príznakov pre vybraný vstupný obraz.
4. Vykonajte porovnanie priebehov tréovania, chyby a úspešnosti dvoch tréovacích algoritmov SGDM, ADAM pre najlepšie štruktúru CNN siete na tréovacích a testovacích dátach pre rozdelenie 60%/40%.
5. Ukážte vplyv DropOut vrstvy na úspešnosť klasifikácie na testovacích dátach pri vybranej štruktúre siete a SGDM tréovacím algoritme.
6. Ukážte vplyv percentuálneho rozdelenia dát na úspešnosť CNN siete. Test vykonajte pre naladenú štruktúru siete a rozdelenia dát tréovacie/testovacie (60%/40%, 80%/20%)